

Alignement Forcé Multi-Niveaux pour le Corpus MOCHA-TIMIT

Untel Trucmuche^{1, 2} Unetelle Machinchose^{1, 3}

(1) Lab, adresse, CP Ville, Pays

utrucmuche@lab.fr, umachinchose@adresse-academique.be

Depuis sa publication en 1999, le corpus MOCHA-TIMIT (Wrench, 1999) est une ressource fondamentale pour la recherche en parole multimodale, avec 200+ publications portant sur l'inversion acoustique-articulatoire (Richmond, 2006), synthèse de la parole (Richmond *et al.*, 2015), reconnaissance automatique (King *et al.*, 2007) et phonologie articulatoire (Ramanarayanan *et al.*, 2013). Ce corpus comprend des enregistrements multimodaux synchronisés de 460 phrases phonétiquement équilibrées du corpus TIMIT. Chaque énoncé fournit quatre types de signaux synchronisés : audio (16 kHz), articulographie électro-magnétique (suivant 8 articulateurs échantillonnés à 500Hz: pointe/lame/dos de langue, lèvre et incisive supérieure/inférieure, vélum), électropalatographie (62 électrodes, 200 Hz), et signal laryngographe (16 kHz). La présence de données EPG et laryngographiques synchronisés est une caractéristique unique qui rend ce corpus particulièrement adapté pour l'étude de l'interaction entre prosodie et articulation. Bien que le corpus inclut 9 locuteurs (5 femmes, 4 hommes, avec 3 996 énoncés validés après contrôle qualité), près de 70% des études publiées limitent leurs analyses à 1–2 locuteurs seulement (généralement msak0 ou fsew0). Cette sous-utilisation résulte d'obstacles techniques : incohérences entre noms de fichiers et contenus, absence d'annotations phonémiques alignées temporellement standardisées pour tous les locuteurs, et manque d'annotations prosodiques (e.g. : syllabes, accent lexical). Afin de rendre accessible la totalité des enregistrements disponibles, nous avons développé une procédure d'alignement et de validation en quatre étapes. **Étape 1—Synchronisation fichiers** : reconnaissance automatique du contenu segmental (via Whisper ; Radford *et al.*, 2023) pour corriger les incohérences nom-contenu. **Étape 2—Contrôle qualité** : inspection manuelle Praat signalant fichiers à bruit/énoncés supplémentaires. **Étape 3—Alignement forcé** : Montreal Forced Aligner (MFA) (McAuliffe *et al.*, 2017) avec modèles anglais britannique générant les frontières phonémiques. **Étape 4—Génération multi-niveaux** : production de 8 niveaux d'annotation par énoncé (Fig. 1) : word (segmentation lexicale), mocha (étiquettes phonémiques SAMPA), ARPAbet (phonèmes MFA US), ARPAbet_stress (marqueurs d'accent lexical 0/1/2), IPA (transcription anglais britannique), IPA_rich (transcription phonétiques étroite), syllable (frontières basées CMUdict), proéminence (domaines d'accents lexicaux primaires et secondaires). Nous avons évalué le fonctionnement de notre procédure en comparant les annotations produites avec les annotations manuelles disponibles pour les locuteurs msak0 et fsew0 (920 énoncés). La précision de classification phonémique atteint le 91,8% pour fsew0 et le 93,1% pour msak0. L'erreur absolue moyenne (MAE) dans l'alignement est de 17,2 (fsew0) et de 19,5 ms (msak0). Le 68% des frontières se trouvent à moins de 20 ms des frontières manuelles, tandis que le 90% est à moins de 50 ms. Erreurs courantes : confusions voyelles brèves /I/-i/ (3,2%), placement frontières silence (erreur médiane 32 ms), ambiguïté tap/flap (2,1%). Ces métriques confirment la fiabilité de la segmentation produite.




FIGURE 1 Exemple d’annotation (locuteur maps0). Tier 1 : word ; tier 2 : mocha (SAMPA-like) ; tier 3 : ARPAbet (MFA_US) ; tier 4 : ARPAbet_stress (MFA_US) ; tier 5 : IPA ; tier 6 : IPA_rich ; tier 7 : syllables ; tier 8 : prominence.

References

KING S., FRANKEL J., LIVESCU K., McDERMOTT E., RICHMOND K. & WESTER M. (2007). Speech production knowledge in automatic speech recognition. *The Journal of the Acoustical Society of America*, **121**(2), 723–742.

MCAULIFFE M., SOCOLOF M., MIHUC S., WAGNER M. & SONDEREGGER M. (2017). Montreal forced aligner: Trainable text-speech alignment using kald. In *Interspeech*, volume 2017, p. 498–502.

RADFORD A., KIM J. W., XU T., BROCKMAN G., MCLEAVEY C. & SUTSKEVER I. (2023). Robust speech recognition via large-scale weak supervision. In *International conference on machine learning*, p. 28492–28518: PMLR.

RAMANARAYANAN V., GOLDSTEIN L. & NARAYANAN S. S. (2013). Spatio-temporal articulatory movement primitives during speech production: Extraction, interpretation, and validation. *The Journal of the Acoustical Society of America*, **134**(2), 1378–1394.

RICHMOND K. (2006). A trajectory mixture density network for the acoustic-articulatory inversion mapping. In *INTER-SPEECH 2006-ICSLP Ninth International Conference on Spoken Language Processing*, p. 1790–Mon3WeS: International Speech Communication Association.

RICHMOND K., LING Z. & YAMAGISHI J. (2015). The use of articulatory movement data in speech synthesis applications: An overview—application of articulatory movements using machine learning algorithms—. *Acoustical Science and Technology*, **36**(6), 467–477.

WRENCH A. A. (1999). The mocha-timit articulatory database. <http://www.cstr.ed.ac.uk/research/projects/artic/mocha.html>.